대규모 게임 로그 데이터를 활용한 배틀그라운드 악성 유저 탐지 모델

프로젝트 기간: 24.09~24.11
인원: 3인
역할: 데이터 수집, 전처리, 모델 설계
기술 스택: XGBoost, Random Forest, Pyspark, PUBG Developer API

목표

경쟁 기반 게임(PUBG)에서 불법 프로그램은 일반 플레이어의 경험에 부정적 영향과 기존 제재는 느리고 수동적인 한계가 존재함.

→ 신고 없이도 게임 내 행동 패턴(게임 로그 데이터)을 분석하여 악성 유저를 능동적으로 식별하는 시스템 구축

데이터 수집: PUBG API 파이프 라인

기존 오픈 데이터 셋은 오래되고, 악성 유저 레이블 존재 X

신뢰할 수 있는 확보를 위하여 PUBG API를 활용하여 데이터 수집을 위한 파이프 라인 구축

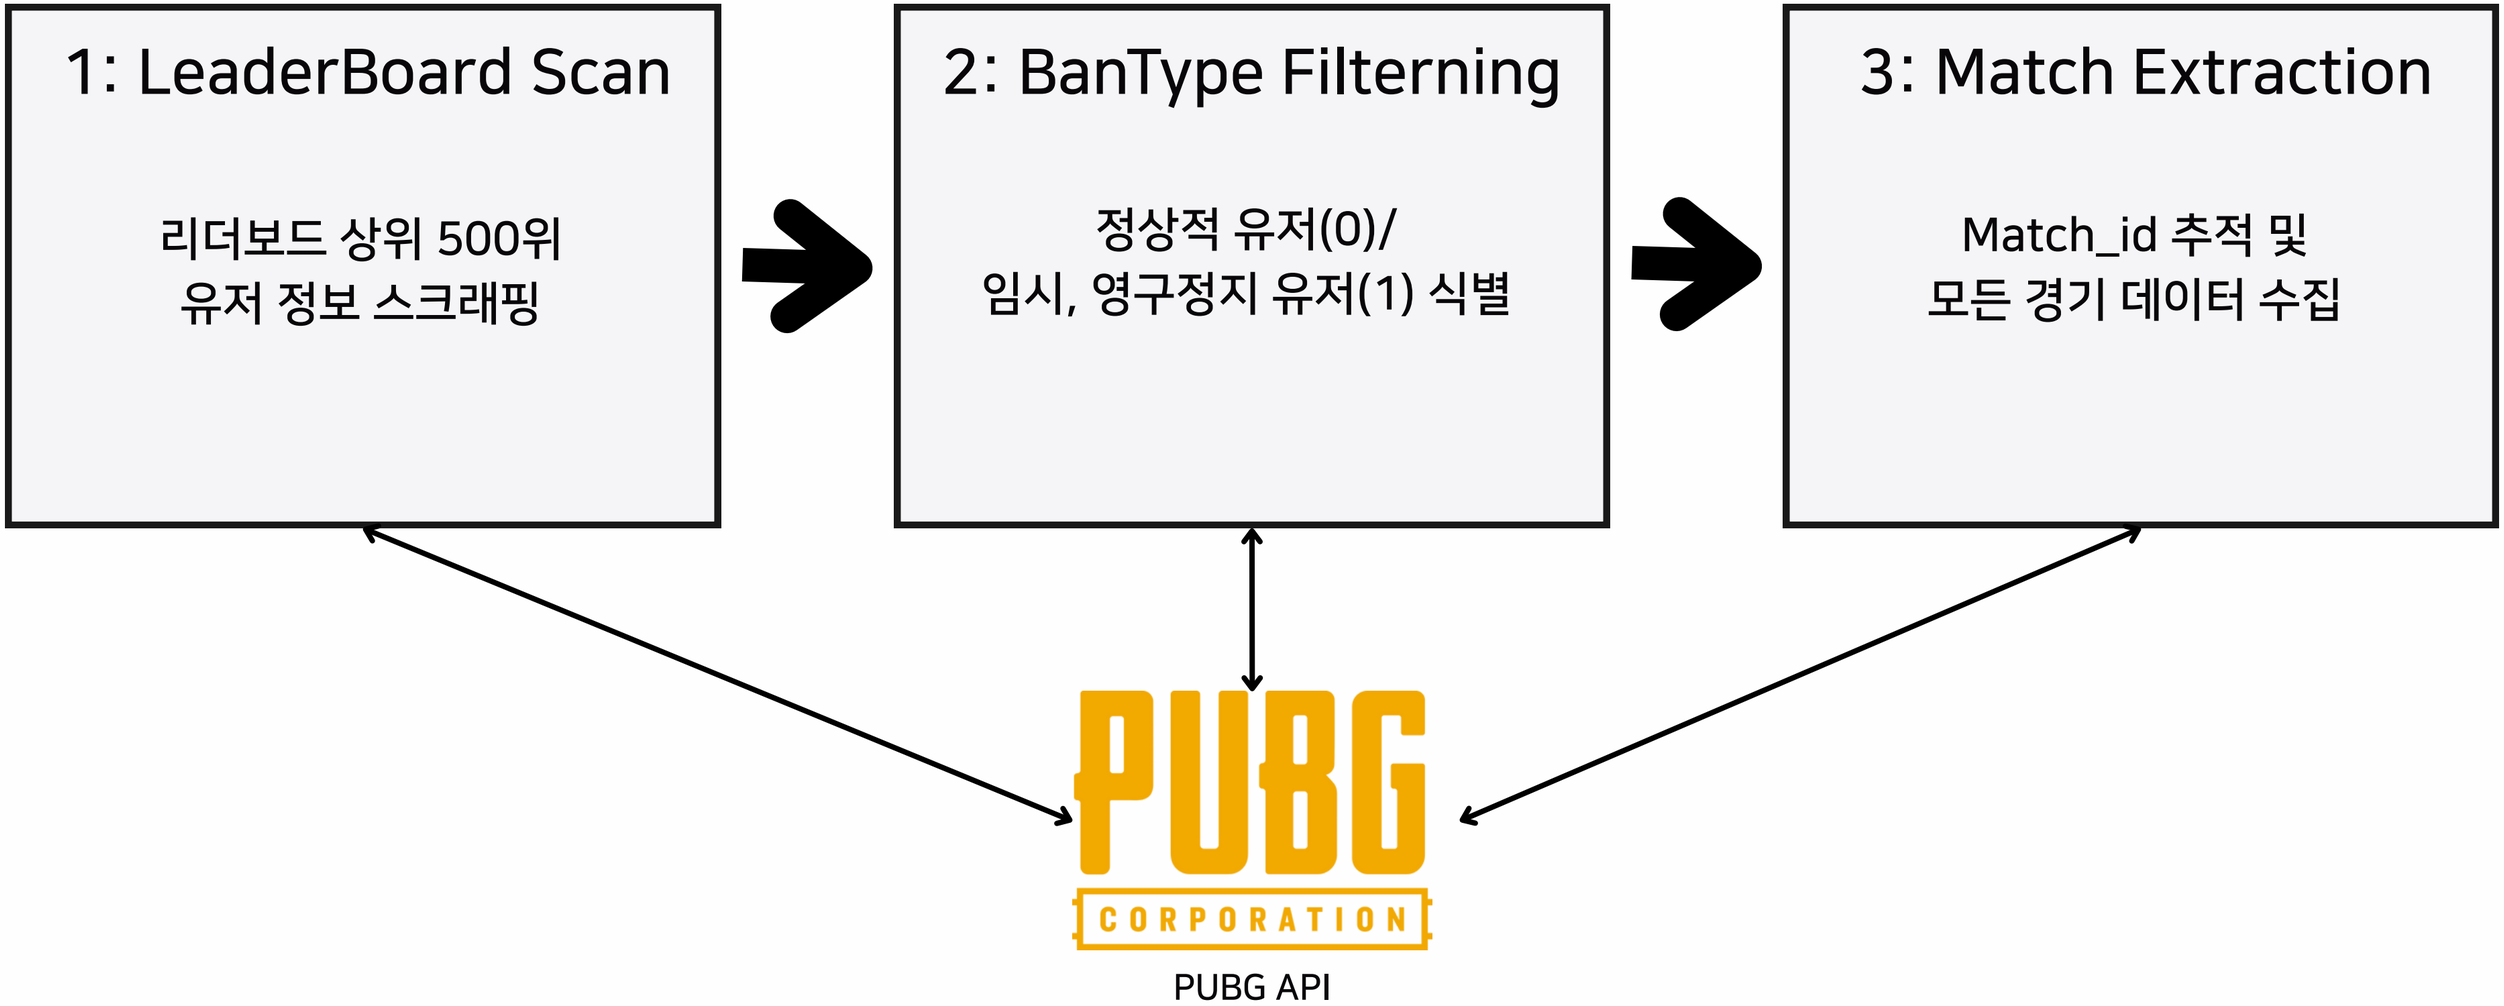

노이즈 제거 및 데이터 정제 로직

유저 정제 로직

데이터 중에서도 노이즈가 될 수 있는
플레이 데이터는 제외했습니다.

이는 특별한 활동 없이 바로 사망한 케이스로
플레이 패턴 분석에 노이즈로 작용하므로
데이터셋에서 제외했습니다.

=> 110만건 이상의 고품질 데이터 확보

데이터 검증 과정: 정상 유저 Vs 악성 유저

→ 독립 표본 T-검정 결과: P-value 0에 수렴

특성	T- 통계량	P-value
kills	39.643	1.82e - 295
assists	37.838	1.26e -272
damageDealt	48.441	0
headshotKills	36.42	4.94-255
walkDistance	14.642	1.65e- 47

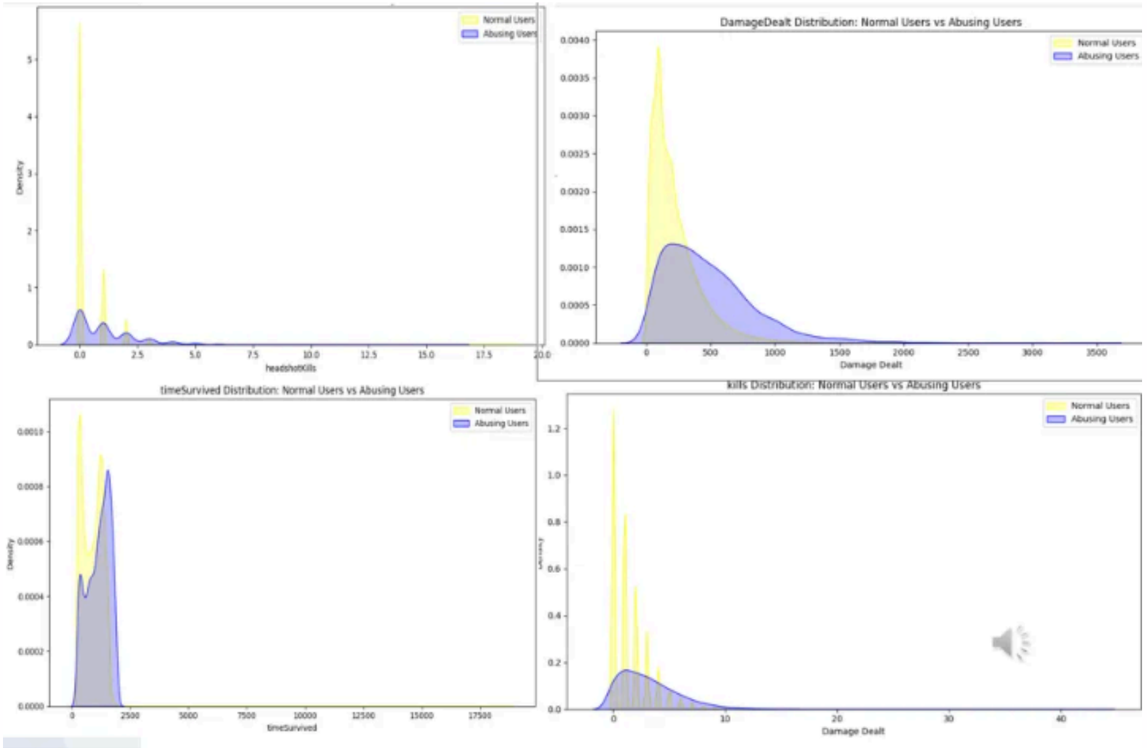

- T-통계량의 값이 (14.642~48.441)으로 악성 그룹이 정상 그룹보다 모든 특성의 평균값이 훨씬 높음

- P-value도 거의 0에 수렴합니다. 이는 평균값에 명백한 차이가 존재하고, 차이가 우연이 아님을 확인

- 정상 유저: 대부분 0쪽에 집중된 분포의 형태를 보여주며 대다수 유저가 이 구간내에 위치합니다. Kill과 Damage의 경우 증가할 수록 빈도가 급격히 감소
- 악성 유저: 정상 유저 대비, 평균이 우측으로 크게 이동해있고 분포도 꼬리가 긴 형태를 보임. 비정상적 프로그램을 통해 비정상적 스텟이 지속적으로 기록

모델링 및 학습 결과

Random Forest와 XGBoost를 사용하여,
정상 유저와 악성 유저를 분류를 수행

전략 1: 데이터 불균형 해소, 피처 선택

1. 정상 데이터 110만건, 악성 데이터 4400건 → 불균형으로 SMOTE 샘플링

2. 피처 중요도와 상관계수로 순위를 통합하여 상위 지표를 학습에 사용

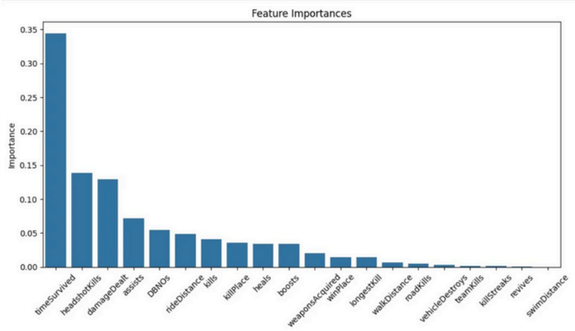

튜닝을 통하여 모델 성능 최적화와 과적합 방지 수행

전략 2: 하이퍼 파라미터 최적화

```
# 하이퍼 파라미터 탐색 및 모델 학습
param_grid = {
    'n_estimators': [50, 100, 200],
    'max_depth': [3, 5, 10],
    'learning_rate': [0.01, 0.1, 0.2],
    'subsample': [0.8, 1.0],
    'colsample_bytree': [0.8, 1.0],
    'gamma': [0, 0.1, 0.3]
}

# XGBoost 모델 정의
xgb_model = xgb.XGBClassifier(use_label_encoder=False, eval_metric='logloss', random_

# 랜덤 서치 객체 정의 (5-fold 교차 검증 적용)
random_search = RandomizedSearchCV(estimator=xgb_model, param_distributions=param_gri
                                   scoring='roc_auc', cv=3, verbose=1, n_jobs=-1, n_iter=50)
```

튜닝을 통하여 모델 성능 최적화와 과적합 방지 수행

학습 결과

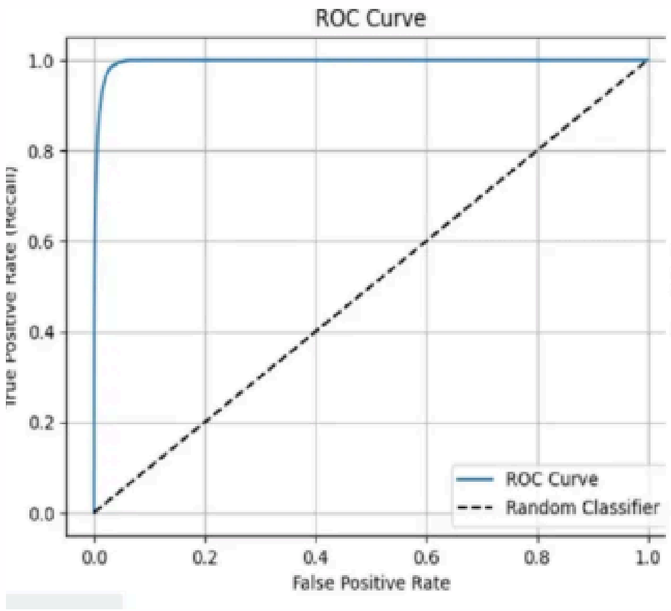

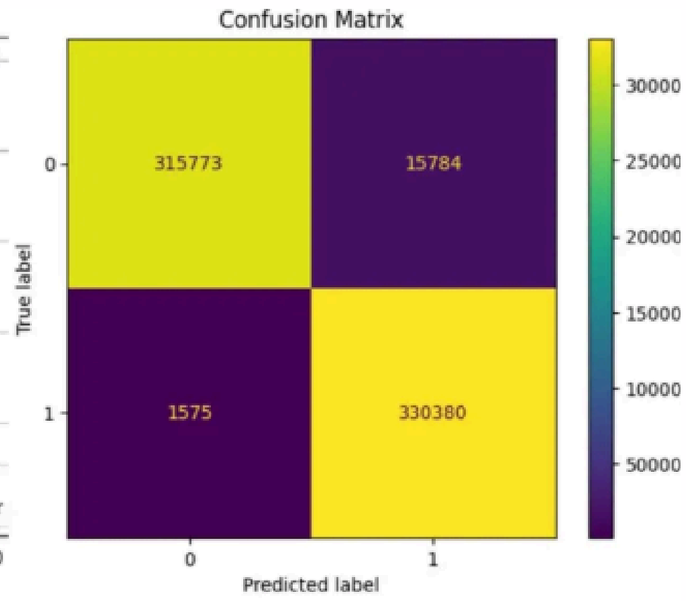

모델	ROC-AUC	정확도	정밀도	재현율	F1-Score
XGBoost	0.996	0.973	0.954	0.995	0.974
Random Forest	0.981	0.931	0.912	0.956	0.933

XGBoost가 정확도: 0.974 / 재현율: 0.954 / 정밀도: 0.995
RF대비 전체적 지표에서 유의미한 성능 향상을 확인

데이터에서 악성 유저와 일반 유저간에 데이터 특성이 뚜렷하고
오버 샘플링을 통해 소수 케이스에도 충분히 학습을 수행하여
대부분의 케이스를 탐지한 것으로 생각됩니다.

분석 웹 서비스 구현

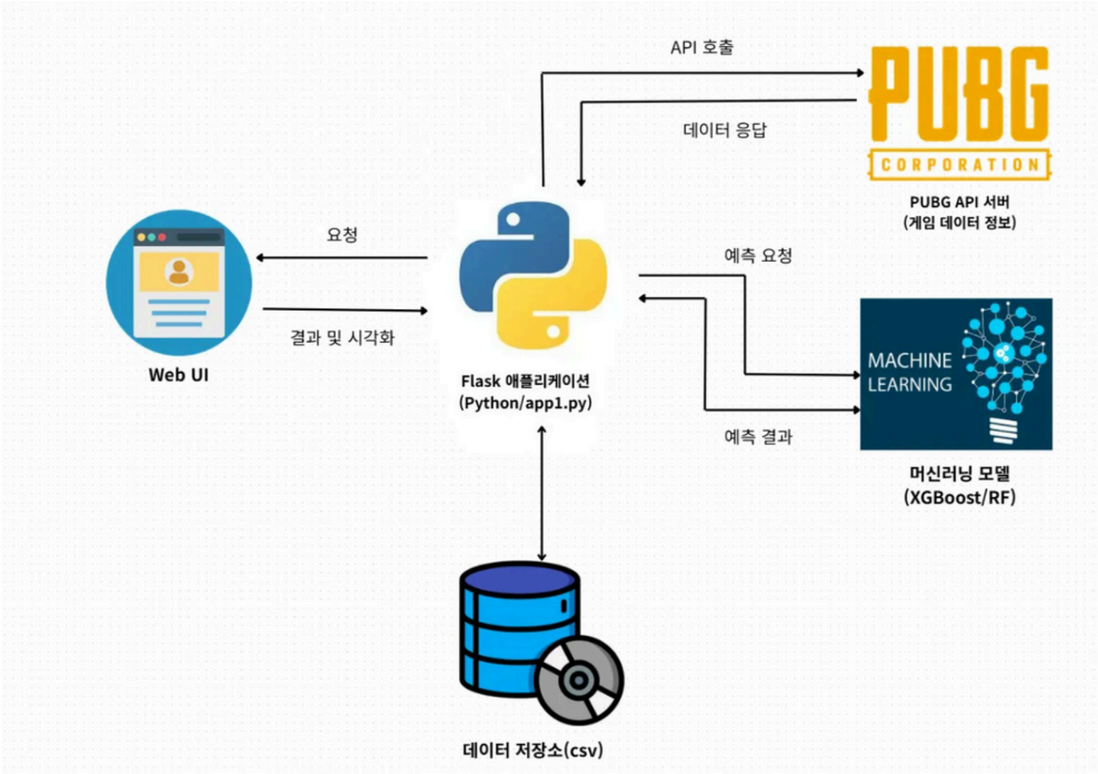

사용자가 플레이어 이름을 입력 → PUBG API를 통해 실시간으로 최신 매치 데이터를 수집

학습된 XGBoost와 Random Forest 모델로 종합 분석, 해당 유저의 위험도를 시각적으로 제공

서비스 UI

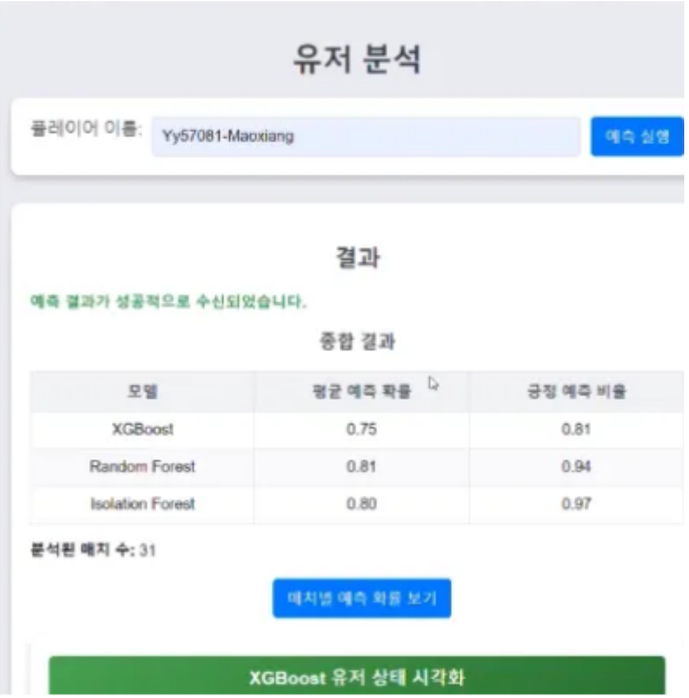

1. 모델 앙상블 기반의 정밀 예측
다중 모델 검증: XGBoost, Random Forest 복수 모델의 예측 확률을 종합 분석
높은 신뢰도: 단일 모델 대비 판단 근거의 객관성과 신뢰성 확보
2. 직관적인 3단계 위험도 분류
분석 결과에 따라 유저 상태를 세분화하여 즉각적인 대응 지원:
일반 (Safe): 예측 확률 0.5 미만
의심 (Caution): 예측 확률 0.5 ~ 0.7
확실 (Critical): 예측 확률 0.7 이상 (악성 유저 판단)

주요 성과

110만건의 데이터 확보
(API기반 자동화 데이터 파이프라인 구축)

99.5% Recall
(XGBoost 모델 악성 유저 탐지률)

분석 웹 서비스 제공
(일반 사용자를 위한 실용적 도구 제공)

아쉬운 점

1. 기술 스택 선정의 적정성
문제점: 데이터 규모에 비해 과도한 인프라(Hadoop, HDFS) 설정으로 초기 개발 리소스 낭비
해결 및 배움: 데이터 크기와 비즈니스 목적에 맞는 최적의 기술 스택 선정 역량의 중요성 체감

2. 데이터 분석 방법론의 체계화
문제점: 라벨링된 데이터임에도 비지도 학습(Isolation Forest)을 우선 적용하는 등 분석 프로세스의 시행착오 발생
성장 지표: 프로젝트 이후 '빅데이터분석기사' 취득 및 정규 분석 프로세스(EDA → 전처리 → 모델링) 학습을 통한 전문성 강화

3. 실무 적용을 위한 모델 설명력
한계점: 현재 모델(XGB, RF)은 블랙박스 성격이 강해, 오탐(False Positive) 발생 시 사용자 설득을 위한 명확한 근거 제시가 어려움
향후 과제: 실제 운영을 위해 XAI(설명 가능한 AI, 예: SHAP, LIME) 도입 및 투명한 제재 근거를 확보하는 보조 시스템 구축 필요